아파트 실거래가 EDA 결과 보고서

> 실행 도구: Python(pandas, NumPy, Matplotlib)

1. 데이터 개요

- 주 분석 파일: `아파트(매매)_실거래가_2017_2026_시계열통합.csv`
- 데이터 크기: **627,611 행 × 20 열**
- 계약일자 범위: **2017-01-01 ~ 2026-08-31**
- 자치구 수: **25 개**, 단지명 수: **7,793 개**

2. 주요 품질 이슈 TOP 10

1. **구조적 결측이 광범위함**: 전체 627,611 행에 하나 이상의 결측 토큰이 있으나, 과거 공개 형식에서 `-`로 제공된 매수자·매도자·거래유형·등기일자 등이 대부분이므로 일괄 오류 처리하면 안 됩니다.
2. **비구조적 결측 후보**: 206 행은 식별·분석 핵심 열 결측이 섞여 있어 별도 확인이 필요합니다.
3. **거래 복합키 잠재 중복**: 28,793 행 / 12,980 그룹입니다. 동일 조건의 복수 정상 거래가 가능하므로 자동 삭제 금지입니다.
4. **전체 20 열 완전 중복**: 0 행 / 0 그룹입니다.
5. **해제 거래 후보**: 해제사유발생일이 있는 17,270 행은 MDD·회복률 계산 포함 여부를 확정해야 합니다.
6. **통계·조건부 이상치 후보**: 고유 115,548 행입니다. 이는 오류 확정값이 아니라 주변 거래 비교 대상입니다.

7. **건축년도 > 계약연도**: 40 행으로, 분양권·입주권/준공 전 거래 또는 원천 오류를 구분해야 합니다.
8. **시계열 이상 분기**: 4,076 개 단지×면적구×분기가 직전·rolling 기준에서 급변했습니다.
9. **MDD 신뢰도 낮은 그룹**: 5,770 개 단지×면적구는 관측 분기 또는 거래건수가 부족합니다.
10. **단지 exact join 미매칭**: 485,414 행(77.34%)이며, 단지명/주소 표기 정규화·외부 매핑이 필요합니다.

3. 중복

- Level A(원본 20 열 완전 동일): **0 행 / 0 그룹**
- Level B(`NO` 중복): **606,698 영향 행 / 84,017 중복 키 그룹**
- Level C(시군구·단지명·면적·계약일·금액·층·도로명): **28,793 행 / 12,980 그룹**
- Level D(공백·구두점 제거 후 유사 표기): **19 개 정규화 그룹**
- 권고: 거래 고유 ID 나 등기 식별자가 없으므로 중복 후보를 개수만으로 삭제하지 말고 `04_transaction_duplicate_candidates.csv` 에서 원본 행을 검토하십시오.

4. 결측

- 결측 토큰(`NaN`, 빈 문자열, 공백, `-`, `NA`, `N/A`, `NULL`, `None`) 중 하나 이상을 가진 행: **627,611 행(100.00%)**
- 구조적 결측만 가진 행: **627,405 행**
- 비구조적 결측 가능 행: **206 행**
- 결측률 상위 열:
- 해제사유발생일: 610,341 건 (97.25%)
- 동: 446,451 건 (71.13%)
- 매도자: 437,337 건 (69.68%)

- 매수자: 437,337 건 (69.68%)
- 등기일자: 429,882 건 (68.49%)
- 중개사소재지: 399,800 건 (63.70%)
- 거래유형: 386,330 건 (61.56%)
- 도로명: 206 건 (0.03%)

5. 이상치

- 물리·논리 범위 검사는 면적/금액 0 이하, 유효하지 않은 계약일자, 건축년도-계약연도 역전, 층 숫자 변환·범위를 별도 점검했습니다.
- 전역 IQR 과 MAD 는 **삭제 기준이 아니라 후보 탐색 기준**으로만 사용했습니다.
- 가격은 `단지명 × 면적구 × 계약연도`의 ㎡당가격 MAD 기준을 추가 적용했습니다(n≥5).
- 전역·조건부 기준 중 하나 이상에 걸린 고유 행: **115,548 행(18.41%)**
- 조건부 MAD 후보: **20,614 행**
- 주변 거래 파일은 조건부 MAD 후보마다 같은 단지·면적구의 시간상 최근 5 건을 제공합니다.

6. 시계열 품질

- 단지×면적구 그룹: **13,761 개**
- 시계열 급변 후보 분기: **4,076 개**
- MDD 신뢰도 `LOW`: **5,770 개 그룹**
- 고점/저점 원천 거래는 거래 8 건 이상·관측 4 분기 이상인 그룹만 추적했습니다. 고점·저점이 단 1 건 거래로 결정되는지는 `13_timeseries_quality.csv`의 분기 건수와 `14_peak_trough_source_rows.csv`로 판단할 수 있습니다.
- 권고: 해제 거래와 조건부 이상치 1 건이 분기 중앙값·고점·저점을 바꾸는지 민감도 분석 후 MDD/회복률을 확정하십시오.

7. 좌표

- 주 원천 거래 파일에는 좌표가 없어 별도 입지 테이블 `아파트_입지_DATA.csv`의 WGS84 를 점검했습니다.
- 위도 37~38, 경도 126~128 범위·결측·X/Y 뒤바뀜 후보: **14 행**
- GRS80TM 열은 현재 입지 테이블에 없어 단위·축 순서 검증 대상이 아닙니다.

8. Join Key 품질

- 기준: 거래 `시군구 + 단지명` ↔ 단지 `법정동주소 + 단지명`, 공백·구두점·대소문자 정규화 exact match
- 거래행 매칭: **142,197 행(22.66%)**
- 미매칭: **485,414 행(77.34%)**
- 단지 차원 중복키: **3 개**, join explosion 위험 거래행: **61 행**
- exact match 실패는 곧 미존재를 뜻하지 않습니다. 법정동/도로명 주소와 단지 별칭을 이용한 승인형 매핑 테이블이 필요합니다.

9. MDD·회복률 분석에 미칠 영향

- 중복 후보를 모두 포함하면 특정 분기의 거래건수 가중이 커지고, 모두 제거하면 정상적인 동시 거래를 잃을 수 있습니다.
- 해제 거래는 실제 체결 시계열과 취소 시계열을 섞어 고점·저점을 왜곡할 수 있습니다.
- 거래 1 건뿐인 분기와 장기 공백은 분기 중앙값을 불안정하게 하며 MDD/회복률의 시점을 이동시킬 수 있습니다.
- 고가 단지·대형 평형은 전역 IQR 에서 정상임에도 이상치가 될 수 있으므로 조건부 기준과 주변 거래를 우선하십시오.
- 단지 조인 미매칭을 누락시키면 표본 선택 편향이 발생할 수 있습니다.

10. 전처리 후보와 사람의 결정이 필요한 항목

아래 순위는 **오류일 가능성만의 순서가 아니라, 잘못 처리했을 때 MDD·회복률 결과를 크게 바꾸는 순서**입니다. 예시는 모두 실제 EDA 산출물에서 가져왔으며, `원본 행`은 `아파트(매매)_실거래가_2017_2026_시계열통합.csv`의 물리적 CSV 행 번호입니다.

우선순위	검토 대상	규모	핵심 질문
1	해제 거래	17,270 행	취소된 거래를 가격 시계열에 포함할 것인가?
2	거래 복합키 잠재 중복	12,980 그룹 / 28,793 행	같은 거래의 중복 수집인가, 같은 조건의 별도 거래인가?
3	단지 조인 미매칭	485,414 행	어떤 단지 마스터 행과 연결할 것인가?
4	조건부 가격 이상치	20,614 행	정상 고가·저가 거래인가, 입력·계약 유형 문제인가?
5	건축년도 역전	40 행	준공 전 거래인가, 건축년도 오류인가?
6	비구조적 결측	206 행	핵심 주소 정보를 보완할 수 있는가?
7	MDD 신뢰도 LOW	5,770 그룹	관측이 희소한 그룹에서 MDD 를 계산할 것인가?

10.1 우선순위 1 — 해제 거래

쉽게 말하면: 계약이 신고된 뒤 취소된 것으로 보이는 거래입니다. 이 가격을 정상 체결 가격처럼 사용하면 존재하지 않는 고점이나 저점이 생길 수 있습니다.

실제 예시:

원본 행	단지	계약일	면적(㎡)	층	거래금액(만원)	해제사유발생일
273626	낙성대현대(296)	2020-02-21	59.78	9	59,500	20200817

- 추적 ID: `아파트(매매)_실거래가_2017_2026_시계열통합.csv:273626`
- 이 행을 유지하면 해당 분기의 중앙가격과 고점·저점 계산에 들어갑니다. 제외하면 시계열에서 사라집니다.
- **사람의 결정:** `EXCLUDE_FROM_METRIC`을 기본 검토안으로 두되, 해제일 의미와 재신고 거래 존재 여부를 확인해 `KEEP` 또는 별도 취소 시계열로 관리합니다.

10.2 우선순위 2 — 거래 복합키 잠재 중복

쉽게 말하면: 단지·날짜·면적·층·가격이 같아 같은 거래처럼 보이지만, 실제로는 같은 날 같은 조건으로 여러 세대가 거래됐을 수도 있습니다.

실제 `TX_11639` 그룹:

원본 행	NO	단지	계약일	면적(㎡)	층	거래금액(만원)
492	104461	주주베 B	2017-01-05	14.89	7	13,200
493	104462	주주베 B	2017-01-05	14.89	7	13,200

- 위 행들은 핵심 거래 조건이 같고 `NO`만 다릅니다. `NO`가 수집 배치용 번호라면 중복일 수 있지만, 실제 거래 식별자라면 서로 다른 거래일 수 있습니다.
- 한 행만 남기면 거래건수와 분기 중앙값의 가중이 달라질 수 있습니다.
- **사람의 결정:** 등기일자·동 정보·원천 거래 ID를 추가 대조하기 전에는 자동 삭제하지 않습니다. 확인 후 `KEEP` 또는 중복 행에 `DROP`을 기록합니다.

10.3 우선순위 3 — 단지 조인 미매칭

쉽게 말하면: 거래 행은 존재하지만 `시군구 + 단지명` 정규화 키가 단지정보 마스터와 정확히 일치하지 않은 경우입니다.

실제 예시:

원본 행	법정동 주소	단지	도로명	계약일	거래금액(만원)
3	서울특별시 도봉구 도봉동	한신	마들로 859-19	2017-01-01	30,750
4	서울특별시 도봉구 도봉동	한신	마들로 859-19	2017-01-01	31,700

- 미매칭은 "존재하지 않는 단지"라는 뜻이 아닙니다. 단지 마스터의 누락, 단지 별칭, 법정동/도로명 주소 차이, 재건축 전후 명칭 차이일 수 있습니다.
- 미매칭 행을 모두 버리면 전체 거래의 77.34%가 제외되어 표본 선택 편향이 매우 커집니다.
- **사람의 결정:** `단지명 + 법정동주소 + 도로명주소` 후보를 비교한 승인형 매핑 테이블을 만들고, 확정 전에는 `NEED_EXTERNAL_CHECK`로 둡니다.

10.4 우선순위 4 — 조건부 가격 이상치

쉽게 말하면: 서울 전체에서 비싸거나 싼 것이 아니라, **같은 단지·비슷한 면적·같은 연도**의 거래들과 비교했을 때 유난히 다른 가격입니다.

실제 검토 대상 `미성 | 40~60 ㎡ | 2020`:

구분	원본 행	계약일	거래금액(만원)	면적(㎡)	층
검토 대상	338151	2020-12-02	159,000	46.54	8
주변 거래	335636	2020-11-23	68,500	50.14	5
주변 거래	341071	2020-12-12	68,800	50.14	13

구분	원본 행	계약일	거래금액(만원)	면적(㎡)	층
주변 거래	341001	2020-12-12	70,000	50.14	5
주변 거래	334491	2020-11-18	65,500	52.45	6
주변 거래	343020	2020-12-19	68,000	50.14	2

- 검토 대상의 그룹 MAD robust z-score 절댓값은 **14.98** 입니다. 통계적으로 튀지만 정상 특수층·한강 조망·내부거래·지분거래일 가능성도 있습니다.
- 주변 5 건은 자동 삭제의 근거가 아니라 원본 계약을 재확인할 순서를 정하는 비교 자료입니다.
- **사람의 결정:** 주소·동·층·계약 유형과 원천 공시를 확인하여 `KEEP`, `CORRECT`, `EXCLUDE_FROM_METRIC` 중 하나를 선택합니다.

10.5 우선순위 5 — 건축년도 역전

쉽게 말하면: 계약연도보다 건축년도가 뒤에 있습니다. 일반 완공 아파트 거래라면 모순이지만 분양권·입주권 또는 준공 전 계약이면 정상일 수 있습니다.

실제 예시:

원본 행	단지	계약일	건축년도	거래금액(만원)	판정 전 확인사항
92904	유호루하스	2017-11-17	2018	11,998	분양권·입주권/준공 전 계약 여부
175822	골든카운티	2018-09-08	2019	110,000	분양권·입주권/준공 전 계약 여부
177158	청계리버팰리스 A	2018-09-11	2019	27,000	분양권·입주권/준공 전 계약 여부

- 이 40 행을 즉시 오류로 고치면 정상적인 준공 전 거래를 훼손할 수 있습니다.
- 반대로 기존 아파트 거래인데 건축년도가 미래라면 단지 마스터 또는 원천값 보정이 필요합니다.

- **사람의 결정:** 거래 유형과 입주·준공일을 외부 확인해 `KEEP`, `CORRECT`, 또는 시계열 지표의 `EXCLUDE_FROM_METRIC`을 선택합니다.

10.6 우선순위 6 — 비구조적 결측

쉽게 말하면: 과거 포맷상 당연히 비는 매수자·매도자 같은 열이 아니라, 주소·단지 식별이나 핵심 분석에 필요한 열이 비어 있는 경우입니다.

실제 예시:

원본 행	단지	계약일	결측 열	도로명 원본값	상태
440622	롯데캐슬리버파크 시그니쳐	2024-02-06	동 | 도로명 | 해제사유발생일 | 등기일자	-	POSSIBLE_DATA_QUALITY_ISSUE

- 도로명이 없어도 시군구·번지·단지명으로 거래 자체를 분석할 수는 있지만, 단지 조인과 주소 표준화 신뢰도가 낮아집니다.
- 임의의 최빈값이나 평균으로 채우면 다른 단지와 잘못 연결될 수 있습니다.
- **사람의 결정:** 동일 `시군구 + 번지 + 단지명`의 일관된 도로명이 확인될 때만 `IMPUTE`; 그렇지 않으면 `NEED_EXTERNAL_CHECK` 또는 조인 지표에서만 `EXCLUDE_FROM_METRIC`으로 둡니다.

10.7 우선순위 7 — MDD 신뢰도 LOW

쉽게 말하면: 데이터가 틀렸다는 의미가 아니라, 거래가 너무 적거나 관측 분기가 짧아 고점·저점과 회복 여부를 믿기 어려운 그룹입니다.

실제 단지×면적구 예시:

단지	면적구	총 거래	관측 분기	기간	구간 내 빈 분기	1 건뿐인 분기
(1-10)	60~85 ㎡	1	1	2025Q3~2025Q3	0	1
세이지움개봉	~40 ㎡	354	1	2025Q2~2025Q2	0	0

- 거래 1 건뿐인 그룹은 하락 구간 자체를 관측할 수 없어 MDD 가 0 처럼 보이더라도 의미가 없습니다.
- 두 번째 예시처럼 거래가 **354 건이어도 모두 한 분기에만 집중**되면 시간에 따른 하락과 회복을 관측할 수 없습니다. 거래건수와 관측기간을 함께 봐야 합니다.
- 거래가 여러 건이어도 관측 분기가 4 개 미만이거나 공백이 길면 고점과 저점이 시장 흐름이 아니라 우연한 한두 건에 의해 결정될 수 있습니다.
- **사람의 결정:** 예를 들어 `총 8건 이상 + 관측 4분기 이상` 같은 최소 기준을 승인하고, 미달 그룹은 MDD·회복률 결과에서 `EXCLUDE_FROM_METRIC` 또는 `UNRESOLVED` 로 표시합니다.

10.8 권장 결정 순서

1. 해제 거래 포함 정책을 먼저 확정합니다.
2. 잠재 중복을 검토해 거래건수의 기준 모집단을 확정합니다.
3. 단지 매핑을 승인해 분석 그룹을 고정합니다.
4. 같은 그룹의 주변 거래와 조건부 이상치를 검토합니다.
5. 건축년도 역전과 핵심 결측을 외부 자료로 확인합니다.
6. 마지막으로 최소 거래건수·관측분기 기준을 적용해 MDD 산출 가능 그룹을 확정합니다.